


فصل ۱

تحلیل عملکرد مدل‌های زبانی در حالت Zero-shot

در گام نخست این پژوهش، عملکرد ذاتی (Baseline Performance) چهارده مدل زبانی بزرگ در پاسخ به 120 سوال از آزمون وکالت سال ۱۴۰۳ را مورد ارزیابی قرار داد. این آزمایش در حالت Zero-Shot، یعنی بدون ارائه هرگونه مثال یا راهنمایی (In-context Learning)، انجام شد تا دانش درونی و توانایی استدلال خام مدل‌ها بدون دسترسی به منابع خارجی سنجیده شود [۱].

شکل ۱.۱ مقایسه دقت مدل‌ها را با تفکیک دو گروه متن‌باز (Open Source) و تجاری (Closed Source) نمایش می‌دهد. نتایج نشان‌دهنده یک عملکرد کلی متوسط است که در آن هیچ مدلی نتوانست به دقت چشمگیری دست یابد. مدل متن‌باز Qwen3-235 با کسب دقت 52.5% به طور غیرمنتظره‌ای در جایگاه نخست قرار گرفت و فرضیه برتری مطلق مدل‌های تجاری را به چالش کشید. پس از آن، مدل‌های DeepSeek R1-T2-Chimera (با دقت 49.2%) و Gemini 2.5 Flash (با دقت 48.3%) به ترتیب در رتبه‌های دوم و سوم قرار گرفتند. در مقابل، مدل‌های خانواده GPT-OSS با دقت تنها 32.5% در انتهای جدول جای گرفتند که بیانگر کمبود داده‌های حقوقی فارسی در فرآیند پیش‌آموزش آن‌هاست.


Zero-shot Accuracy: Open vs Closed



شکل ۱.۱: مقایسه دقت مدل‌ها در حالت Zero-shot با تفکیک مدل‌های متن‌باز و تجاری.


برای کاربردهای عملی، سرعت پاسخ‌دهی یک عامل تعیین‌کننده است. شکل ۲.۱ زمان پاسخ‌دهی (Latency) مدل‌ها را به میلی‌ثانیه نشان می‌دهد. یک شکاف عملکردی عظیم در این بخش مشاهده می‌شود؛ مدل DeepSeek-R1-T2-Chimera با وجود دقت بالا، تأخیری معادل 18.5 ثانیه داشت که آن را برای کاربردهای بلادرنگ نامناسب می‌سازد. در مقابل، خانواده مدل‌هایی مانند Gemini 2.5 و Llama 4 با سرعتی نزدیک به 600 تا 700 میلی‌ثانیه، کارایی زمانی بسیار بهتری را به نمایش گذاشتند. این اختلاف چشمگیر در سرعت، احتمالاً به دلیل تفاوت در پیچیدگی معماری و بهینه‌سازی‌های استنتاجی (Inference Optimization) است [۲].

Zero-shot Mean Latency: Open vs Closed




شکل ۲.۱: میانگین زمان پاسخ‌دهی (Latency) مدل‌ها به میلی‌ثانیه.

شکل ۳.۱ رابطه بین دو معیار کلیدی سرعت و دقت را در یک نمودار پراکندگی به تصویر می‌کشد. این نمودار به وضوح نشان می‌دهد که مدل Qwen3-235 (نقطه بالا و سمت چپ) بهترین تعادل (Trade-off) را میان این دو معیار برقرار کرده است. خوشه‌ای از مدل‌ها مانند Gemini 2.5 Flash نیز در ناحیه «دقت بالا و سرعت بالا» قرار دارند که آن‌ها را به گزینه‌هایی کارآمد برای پیاده‌سازی تبدیل می‌کند.



شکل ۳.۱: نمودار پراکندگی دقت (محور عمودی) در برابر تأخیر (محور افقی)؛ رابطه بین تأخیر پاسخ‌دهی و دقت مدل‌ها.

در نهایت، شکل ۴.۱ به بررسی کالیبراسیون اطمینان مدل‌ها می‌پردازد. یکی از چالش‌های جدی در استفاده از مدل‌های زبانی، پدیده «توهم با اطمینان بالا» (High-confidence Hallucination) است [۳]. مقایسه این نمودار با نمودار دقت (شکل ۱.۱) یک عدم تطابق نگران‌کننده را آشکار می‌سازد. برای مثال، مدل Llama 4 Maverick با وجود دقت متوسط (برابر با 42.5٪)، بالاترین امتیاز اطمینان (4.21) را به خود اختصاص داده است. این رفتار که به عنوان «اعتماد به نفس کاذب» شناخته می‌شود، در حوزه‌های حساس مانند حقوق بسیار خطرناک است. در مقابل، مدل DeepSeek-R1-T2 با ثبت کمترین امتیاز اطمینان (3.56)، دقت بالایی را کسب کرد که نشان‌دهنده کالیبراسیون بهتر و توانایی مدل در تشخیص عدم قطعیت‌های خود است.



شکل ۴.۱: میانگین امتیاز اطمینان (Confidence Score) مدل‌ها.

در مجموع، نتایج فاز Zero-shot نشان داد که دانش پارامتریک مدل‌ها به تنهایی برای پاسخگویی قابل اتکا به سوالات پیچیده حقوقی کافی نیست و این امر ضرورت بررسی روش‌های پیشرفته‌تری مانند Chain-of-Thought و Retrieval-Augmented Generation (RAG) را که در فازهای بعدی این پژوهش به آن‌ها پرداخته می‌شود، بیش از پیش آشکار می‌سازد.