


فصل ۱

رویکرد Zero-shot

در گام نخست این پژوهش، عملکرد ذاتی (Baseline Performance) چهارده مدل زبانی بزرگ در پاسخ به 120 سوال از آزمون وکالت سال ۱۴۰۳ را مورد ارزیابی قرار داد. این آزمایش در حالت Zero-Shot، یعنی بدون ارائه هرگونه مثال یا راهنمایی (In-context Learning)، انجام شد تا دانش درونی و توانایی استدلال خام مدل‌ها بدون دسترسی به منابع خارجی سنجیده شود [۱].

شکل ۱.۱ مقایسه دقت مدل‌ها را با تفکیک دو گروه متن‌باز (Open Source) و تجاری (Closed Source) نمایش می‌دهد. نتایج نشان‌دهنده یک عملکرد کلی متوسط است که در آن هیچ مدلی نتوانست به دقت چشمگیری دست یابد. مدل متن‌باز Qwen3-235 با کسب دقت 52.5% به طور غیرمنتظره‌ای در جایگاه نخست قرار گرفت و فرضیه برتری مطلق مدل‌های تجاری را به چالش کشید. پس از آن، مدل‌های DeepSeek-R1-T2-Chimera (با دقت 49.2%) و Gemini 2.5 Flash (با دقت 48.3%) به ترتیب در رتبه‌های دوم و سوم قرار گرفتند. در مقابل، مدل‌های خانواده GPT-OSS با دقت تنها 32.5% در انتهای جدول جای گرفتند که بیانگر کمبود داده‌های حقوقی فارسی در فرآیند پیش‌آموزش آن‌هاست.


Zero-shot Accuracy: Open vs Closed



شکل ۱.۱: مقایسه دقت مدل‌ها در حالت Zero-shot با تفکیک مدل‌های متن‌باز و تجاری.


برای کاربردهای عملی، سرعت پاسخ‌دهی یک عامل تعیین‌کننده است. شکل ۲.۱ زمان پاسخ‌دهی (Latency) مدل‌ها را به میلی‌ثانیه نشان می‌دهد. یک شکاف عملکردی عظیم در این بخش مشاهده می‌شود؛ مدل DeepSeek-R1-T2-Chimera با وجود دقت بالا، تأخیری معادل 18.5 ثانیه داشت که آن را برای کاربردهای بلادرنگ نامناسب می‌سازد. در مقابل، خانواده مدل‌هایی مانند Gemini 2.5 و Llama 4 با سرعتی نزدیک به 600 تا 700 میلی‌ثانیه، کارایی زمانی بسیار بهتری را به نمایش گذاشتند. این اختلاف چشمگیر در سرعت، احتمالاً به دلیل تفاوت در پیچیدگی معماری و بهینه‌سازی‌های استنتاجی (Inference Optimization) است [۲].

Zero-shot Mean Latency: Open vs Closed




شکل ۲.۱: میانگین زمان پاسخ‌دهی (Latency) مدل‌ها به میلی‌ثانیه.

شکل ۳.۱ رابطه بین دو معیار کلیدی سرعت و دقت را در یک نمودار پراکندگی به تصویر می‌کشد. این نمودار به وضوح نشان می‌دهد که مدل Qwen3-235 (نقطه بالا و سمت چپ) بهترین تعادل (Trade-off) را میان این دو معیار برقرار کرده است. خوشه‌ای از مدل‌ها مانند Gemini 2.5 Flash نیز در ناحیه «دقت بالا و سرعت بالا» قرار دارند که آن‌ها را به گزینه‌هایی کارآمد برای پیاده‌سازی تبدیل می‌کند.



شکل ۳.۱: نمودار پراکندگی دقت (محور عمودی) در برابر تأخیر (محور افقی)؛ رابطه بین تأخیر پاسخ‌دهی و دقت مدل‌ها.

در نهایت، شکل ۴.۱ به بررسی کالیبراسیون اطمینان مدل‌ها می‌پردازد. یکی از چالش‌های جدی در استفاده از مدل‌های زبانی، پدیده «توهم با اطمینان بالا» (High-confidence Hallucination) است [۳]. مقایسه این نمودار با نمودار دقت (شکل ۱.۱) یک عدم تطابق نگران‌کننده را آشکار می‌سازد. برای مثال، مدل Llama 4 Maverick با وجود دقت متوسط (برابر با 42.5٪)، بالاترین امتیاز اطمینان (4.21) را به خود اختصاص داده است. این رفتار که به عنوان «اعتماد به نفس کاذب» شناخته می‌شود، در حوزه‌های حساس مانند حقوق بسیار خطرناک است. در مقابل، مدل DeepSeek-R1-T2 با ثبت کمترین امتیاز اطمینان (3.56)، دقت بالایی را کسب کرد که نشان‌دهنده کالیبراسیون بهتر و توانایی مدل در تشخیص عدم قطعیت‌های خود است [۴].



شکل ۴.۱: میانگین امتیاز اطمینان (Confidence Score) مدل‌ها.


در مجموع، نتایج فاز Zero-shot نشان داد که دانش پارامتریک مدل‌ها به تنهایی برای پاسخگویی قابل اتکا به سوالات پیچیده حقوقی کافی نیست و این امر ضرورت بررسی روش‌های پیشرفته‌تری مانند Chain-of-Thought و Retrieval-Augmented Generation (RAG) را که در فازهای بعدی این پژوهش به آن‌ها پرداخته می‌شود، بیش از پیش آشکار می‌سازد.

۱.۱ رویکرد Few-shot

در گام دوم ارزیابی، تأثیر یادگیری در لحظه (In-context Learning) بر توانایی استدلال حقوقی مدل‌ها مورد بررسی قرار گرفت. در رویکرد Few-shot، به هر مدل 6 نمونه سوال حل شده (شامل سوال، گزینه صحیح و استدلال مختصر) به عنوان ورودی (Prompt) داده شد تا الگوی پاسخگویی را فراگیرد [۱]. هدف از این آزمایش، سنجش این فرضیه بود که آیا ارائه نمونه‌های مشابه می‌تواند شکاف دانش مشاهده شده در حالت Zero-shot را کاهش دهد یا خیر.

شکل ۵.۱ مقایسه دقت مدل‌ها را در حالت Few-shot نشان می‌دهد. برخلاف حالت Zero-shot که مدل‌های متن‌باز پیش‌تاز بودند، در اینجا مدل تجاری Gemini 2.5 Flash با جهشی قابل توجه به دقت 55.0% دست یافت و رتبه نخست را کسب کرد. مدل Grok 4 Fast نیز با دقت 54.2% در جایگاه دوم قرار گرفت. این تغییر در رتبه‌بندی نشان می‌دهد که مدل‌های تجاری بزرگ‌تر (Closed Source) توانایی بالاتری در بهره‌گیری از نمونه‌های آموزشی (Few-shot prompt) دارند [۵]. در میان مدل‌های متن‌باز، Llama 4 Maverick و Qwen3-235 با دقت برابر 45.8% بهترین عملکرد را داشتند، اما همچنان نسبت به رقبای تجاری خود عقب ماندند. مدل‌های خانواده GPT-OSS همچنان با دقت‌های زیر 40%، عملکرد ضعیف خود را تکرار کردند.


Few-shot Accuracy: Open vs Closed Source Models



شکل ۵.۱: مقایسه دقت مدل‌ها در حالت Few-shot با تفکیک مدل‌های متن‌باز و تجاری.


از نظر کارایی زمانی، نتایج نمایش داده شده در شکل ۶.۱ همچنان برتری مطلق مدل‌های سبک‌تر را تایید می‌کند. مدل‌های خانواده Gemini 2.5 با میانگین زمان پاسخگویی حدود 620 میلی‌ثانیه، سریع‌ترین عملکرد را ثبت کردند. در نقطه مقابل، مدل DeepSeek-R1-T2-Chimera با تأخیری بیش از 14 ثانیه، کندترین مدل ارزیابی شده بود. نکته قابل تأمل این است که افزودن نمونه‌های Few-shot به ورودی مدل (که طول توکن‌های ورودی را افزایش می‌دهد)، تأثیر منفی معناداری بر سرعت مدل‌های بهینه شده (مانند Gemini و Llama) نداشته است، اما مدل‌های سنگین‌تر را کندتر کرده است [۶].

Few-shot Mean Latency: Open vs Closed



شکل ۶.۱: میانگین زمان پاسخ‌دهی (Latency) مدل‌ها در حالت Few-shot.

شکل ۷.۱ تحلیل جامع‌تری از رابطه میان سرعت و دقت ارائه می‌دهد. در این نمودار پراکندگی، مدل Gemini 2.5 Flash (نقطه زرد رنگ در بالا سمت چپ) به عنوان «نقطه طلایی» (Sweet Spot) شناخته می‌شود؛ زیرا بالاترین دقت را با یکی از کمترین تأخیرها ترکیب کرده است. این در حالی است که مدل DeepSeek-R1-T2 (نقطه قرمز سمت راست) علیرغم دقت قابل قبول، به دلیل تأخیر بسیار بالا، از ناحیه کارآمدی خارج شده است. این نمودار به وضوح نشان می‌دهد که برای کاربردهای عملیاتی حقوقی، مدل‌هایی که در نیمه چپ و بالای نمودار قرار دارند (مانند Gemini و Grok)، گزینه‌های برتر هستند.



شکل ۷.۱: نمودار تعامل سرعت و دقت (Speed vs Accuracy Trade-off) در حالت Few-shot.

نهایتاً، شکل ۸.۱ وضعیت کالیبراسیون اطمینان مدل‌ها را بررسی می‌کند. یک یافته مهم در این بخش، کاهش کلی میانگین اطمینان در برخی مدل‌های دقیق‌تر است. برای مثال، مدل DeepSeek-R1-T2 میانگین اطمینان خود را به 3.24 کاهش داده است که نشان‌دهنده احتیاط بیشتر مدل در مواجهه با پرامپت‌های طولانی‌تر است. در مقابل، مدل GPT-4.1 Mini با وجود دقت پایین (41.7٪)، به طور نگران‌کننده‌ای بالاترین سطح اطمینان (4.53) را گزارش کرده است. این «اطمینان کاذب» (Overconfidence) در مدل‌های ضعیف‌تر، ریسک استفاده از آن‌ها را در سامانه‌های حساس حقوقی افزایش می‌دهد، زیرا توانایی تشخیص مرزهای دانش خود را ندارند [۷].

Few-shot Mean Confidence: Open vs Closed Source Models




شکل ۸.۱: میانگین امتیاز اطمینان (Confidence Score) مدل‌ها در حالت Few-shot.

در مجموع، گذار از Zero-shot به Few-shot منجر به بهبود عملکرد مدل‌های تجاری (به ویژه Gemini و Grok) شد، اما مدل‌های متن‌باز تغییر چشمگیری را تجربه نکردند. این امر حاکی از آن است که معماری مدل‌های تجاری احتمالاً برای یادگیری در متن (In-context Learning) بهینه‌تر شده است. با این حال، حتی بهترین دقت کسب شده (55%) هنوز برای یک سامانه مشاور حقوقی قابل اتکا کافی نیست و نیاز به روش‌های استدلالی عمیق‌تر (مانند Chain-of-Thought) را برجسته می‌کند [۸].

۲.۱ تأثیر یادگیری در متن (Zero-shot vs. Few-shot)

برای درک دقیق‌تر تأثیر افزودن نمونه‌های آموزشی به ورودی مدل‌ها، مقایسه‌ای مستقیم بین عملکرد Zero-shot و Few-shot انجام شد.

شکل ۹.۱ مقایسه پهلو-به-پهلو (Side-by-Side) دقت مدل‌ها در دو حالت را نشان می‌دهد. همان‌طور که مشاهده می‌شود، پاسخ مدل‌ها به تکنیک Few-shot یکسان نبوده است. مدل‌هایی مانند Grok 4 Fast و Gemini 2.5 Flash جهش مثبتی را تجربه کرده‌اند که نشان‌دهنده توانایی بالایی آن‌ها در انطباق با الگوهای جدید است. در مقابل، برخی مدل‌های قدرتمند در حالت Zero-shot مانند Qwen3-235، در مواجهه با نمونه‌های Few-shot دچار افت عملکرد شده‌اند.




شکل ۹.۱: مقایسه دقت مدل‌ها در دو حالت Zero-shot (آبی روشن) و Few-shot (سرمه‌ای).

برای کمی‌سازی این تغییرات، شکل ۱۰.۱ میزان تغییر دقت (Delta Accuracy) را به درصد نشان می‌دهد. نتایج شگفت‌انگیز است:

بزرگترین برندگان: مدل Grok 4 Fast با ۱۰٪ افزایش دقت، بیشترین بهره را از نمونه‌های Few-shot برده است. پس از آن، مدل‌های خانواده GPT-OSS و Gemini 2.5 Flash با رشدهای ۵٪ تا ۶.۷٪ قرار دارند. این رشد نشان می‌دهد که این مدل‌ها پتانسیل نهفته‌ای داشتند که با هدایت صحیح (Prompting) فعال شده است.

بزرگترین بازندگان: در کمال تعجب، مدل Qwen3-235 که قهرمان حالت Zero-shot بود، با افت ۶.۷٪- مواجه شد. همچنین GPT-4o-mini (۵٪-) و DeepSeek-R1-T2 (۴.۲٪-) نیز عملکرد ضعیف‌تری نشان دادند.

این پدیده که به عنوان «تداخل منفی» (Negative Transfer) یا «حواس‌پرتی با نمونه‌ها» شناخته می‌شود، زمانی رخ می‌دهد که نمونه‌های ارائه شده (Few-shot examples) با دانش درونی مدل تعارض پیدا می‌کنند یا باعث سردرگمی مدل در تشخیص الگوی اصلی می‌شوند [۹]. این یافته مهم نشان می‌دهد که استراتژی Few-shot همیشه راهگشا نیست و برای برخی مدل‌ها (به‌ویژه مدل‌های متن‌باز خاص)، تکیه بر دانش درونی (Zero-shot) موثرتر است.



شکل ۱۰.۱: نمودار تغییرات دقت (Delta) مدل‌ها پس از اعمال روش Few-shot. مقادیر سبز نشان‌دهنده بهبود و مقادیر قرمز نشان‌دهنده افت عملکرد هستند.

۳.۱ رویکرد Zero-shot Chain of Thought (Explain-to-Predict)


در گام سوم ارزیابی، از روش Explain-to-Predict (E2P) در قالب Zero-shot Chain of Thought (CoT) استفاده شد. در این روش، از مدل خواسته می‌شود پیش از اعلام گزینه نهایی، ابتدا استدلال گام‌به‌گام خود را ارائه دهد. هدف از این آزمایش، بررسی این فرضیه است که آیا وادار کردن مدل به «تفکر صریح» (Explicit Reasoning) می‌تواند کیفیت پاسخ‌های حقوقی را بهبود بخشد و شکاف عملکردی مشاهده شده در مراحل قبل را جبران کند یا خیر [۸].

شکل ۱۱.۱ عملکرد مدل‌ها را در این سناریو نمایش می‌دهد. نتایج حاکی از یک جهش عملکردی چشمگیر در برخی مدل‌ها است. مدل Gemini 2.5 Flash با ثبت رکورد دقت ۵۷.۵٪، بالاترین عملکرد را در میان تمامی روش‌های تست شده تا کنون (Zero-shot و Few-shot) به نام خود ثبت کرد. این افزایش دقت نشان می‌دهد که مکانیزم‌های استنتاجی (Reasoning Capabilities) در مدل‌های پیشرفته تجاری، با استراتژی CoT به خوبی فعال می‌شوند [۱۰].

در سوی دیگر، مدل‌های Grok 4 Fast با ۴۸.۳٪ و Qwen3-235 با ۴۷.۵٪ در رتبه‌های بعدی قرار گرفتند. نکته قابل توجه، بهبود نسبی عملکرد مدل‌های GPT-OSS است که توانستند از قعر جدول فاصله بگیرند (دقت ۴۵٪ برای نسخه ۱۲۰)، که نشان می‌دهد ضعف دانشی آن‌ها تا حدی با استدلال منطقی قابل

جبران است.


Zero-shot CoT (E2P) Accuracy



شکل ۱۱.۱: مقایسه دقت مدل‌ها در روش Zero-shot Chain of Thought (E2P).


فعال‌سازی زنجیره افکار هزینه سنگینی بر کارایی زمانی مدل‌ها تحمیل کرده است. شکل ۱۲.۱ نشان می‌دهد که میانگین زمان پاسخگویی در اکثر مدل‌ها به شدت افزایش یافته است. مدل DeepSeek-R1-T2-Chimera با ثبت میانگین تأخیر خیره‌کننده 20,684 میلی‌ثانیه (بیش از 20 ثانیه)، عملاً برای تعاملات بلادرنگ (realtime) غیرقابل استفاده شده است [۲].

با این حال، مدل Gemini 2.5 Flash Lite شگفتی‌ساز این بخش است؛ این مدل توانسته با حفظ سرعت بسیار بالا (841 میلی‌ثانیه)، دقتی قابل قبول (46.7%) ارائه دهد که آن را به کارآمدترین گزینه برای کاربردهای عملی تبدیل می‌کند.




شکل ۱۲.۱: میانگین زمان پاسخ‌دهی (Latency) مدل‌ها در فرآیند تولید استدلال و پاسخ.

نمودار پراکندگی در شکل ۱۳.۱، تمایز آشکاری را میان مدل‌ها ترسیم می‌کند. مدل Gemini 2.5 Flash به تنهایی در ناحیه «دقت بالا - سرعت بالا» قرار دارد که نشان‌دهنده معماری بهینه آن برای وظایف استدلالی است. در مقابل، مدل‌های DeepSeek و GPT-OSS-20 (نقاط سمت راست نمودار) در ناحیه «ناکارآمد» قرار گرفته‌اند، جایی که افزایش زمان پردازش منجر به بهبود متناسبی در دقت نشده است.



شکل ۱۳.۱: نمودار تعامل سرعت و دقت در حالت Zero-shot CoT.

شکل ۱۴.۱ تغییرات معناداری را در الگوی اطمینان مدل‌ها نشان می‌دهد. برخلاف حالت Zero-shot که مدل‌های ضعیف دچار اعتماد به نفس کاذب بودند، در روش CoT شاهد یک «تعدیل اطمینان» هستیم. مدل Claude Haiku 4.5 با کاهش اطمینان خود به 3.75، رفتاری محافظه‌کارانه‌تر در پیش گرفته است. در مقابل، مدل GPT-OSS-20 همچنان با اطمینان بالا (4.35) و دقت بسیار پایین (32.5%)، بدترین کالبراسیون را دارد که نشان‌دهنده ناتوانی آن در ارزیابی صحیح استدلال‌های خود است [۱۰].



شکل ۱۴.۱: میانگین امتیاز اطمینان مدل‌ها در روش Zero-shot CoT.


روش Zero-shot CoT توانست سقف عملکردی مدل‌ها را به 57.5% ارتقا دهد، اما این بهبود به قیمت افزایش چشمگیر زمان پردازش تمام شد. نتایج نشان می‌دهد که «تفکر قبل از پاسخ‌دهی» برای مدل‌های پیشرفته (مانند Gemini) بسیار سودمند است، اما برای مدل‌های ضعیف‌تر (مانند GPT-OSS)، صرفاً منجر به تولید متن بیشتر بدون بهبود دقت می‌شود (Hallucination Amplification).

۴.۱ تحلیل عمیق رفتار استدلالی و کارایی توکن

در این بخش، به کالبدشکافی دقیق‌تر فرآیند تولید پاسخ می‌پردازیم تا درک کنیم مدل‌ها «چگونه» به پاسخ رسیده‌اند. داده‌های جدید (مانند طول استدلال، مصرف توکن و پایداری) دیدگاه‌های ارزشمندی درباره کیفیت تفکر مدل‌ها ارائه می‌دهند [۱۲].


یکی از شاخص‌های رفتاری مهم در مدل‌های زبانی، رابطه بین «حجم متن تولیدی» و «صحت پاسخ» است. شکل ۱۵.۱ میانگین تعداد توکن‌های تولید شده (Completion Tokens) را برای پاسخ‌های صحیح (سبز) و نادرست (قرمز) مقایسه می‌کند. در اکثر مدل‌های مورد بررسی، به‌ویژه مدل‌های ضعیف‌تر مانند GPT-OSS-20 و Grok 4 Fast، مشاهده می‌شود که میانگین توکن‌ها در پاسخ‌های نادرست به طور معناداری

بیشتر از پاسخ‌های صحیح است. برای مثال، Grok 4 Fast در پاسخ‌های نادرست به طور میانگین 1894 توکن تولید کرده است، در حالی که برای پاسخ‌های صحیح 1488 توکن مصرف کرده است. این اختلاف 400 توکنی نشان می‌دهد که مدل وقتی در یافتن مسیر استدلالی صحیح ناتوان است، به «تولید بیهوده متن» (Verbose Hallucination) روی می‌آورد و سعی می‌کند با طولانی کردن پاسخ، فقدان منطق صحیح را جبران کند [۱۳]. در مقابل، مدل‌های کارآمدتری مانند Gemini 2.5 Flash و Claude Haiku رفتار متفاوتی دارند؛ تفاوت حجم توکن در پاسخ‌های درست و غلط آن‌ها بسیار ناچیز است (مثلاً در Gemini تنها حدود 2.5 توکن اختلاف وجود دارد: 83.6 vs 81.2). این «پایداری حجمی» نشان‌دهنده استراتژی استدلالی مشخص و منضبط در این مدل‌هاست.




شکل ۱۵.۱: مقایسه میانگین توکن‌های تولید شده در پاسخ‌های صحیح (سبز) و نادرست (قرمز).

شکل ۱۶.۱ رابطه بین «طول توضیحات» (تعداد کلمات استدلال) و درستی پاسخ را نشان می‌دهد. یک الگوی رفتاری بسیار جالب در اینجا مشاهده می‌شود؛ استدلال‌های طولانی‌تر همیشه بهتر نیستند. مدل Claude Haiku 4.5 با تولید میانگین 57 کلمه برای پاسخ‌های صحیح و 56 کلمه برای غلط، پایدارترین رفتار را دارد. در مقابل، مدل‌های ضعیف‌تر مانند Grok 4 Fast و Llama 4 Scout در پاسخ‌های نادرست خود تمایل به تولید متن طولانی‌تری دارند (نقاط قرمز در سمت راست نمودار)، که این پدیده «پرگویی در شکست» (Verbosity in Failure) نامیده می‌شود و نشان‌دهنده تلاش ناموفق مدل برای پوشاندن ضعف استدلالی است.




شکل ۱۶.۱: توزیع طول توضیحات (Explain Length) برای پاسخ‌های صحیح (سبز) و نادرست (قرمز).

برای درک بهتر رابطه بین کارایی و دقت، شکل ۱۷.۱ نمودار حبابی کارایی توکن را نمایش می‌دهد که در آن محور افقی «کل توکن‌های مصرفی» و محور عمودی «دقت» است. مدل‌های Gemini 2.5 Flash و Llama 4 Scout در گوشه بالا-چپ نمودار (خوشه کارآمد) قرار دارند؛ این یعنی آن‌ها با مصرف توکن کمتر (حدود 600-700 توکن)، به دقت بالاتری دست یافته‌اند. این «ادعا در استدلال» نشانه بلوغ مدل در درک حقوقی است. در سوی دیگر، مدل Grok 4 Fast (حباب بزرگ در سمت راست) با مصرف میانگین بیش از 2500 توکن، ناکارآمدترین مدل محسوب می‌شود.




شکل ۱۷.۱: نمودار کارایی توکن؛ مدل‌های سمت چپ و بالا کارآمدترین‌ها هستند.

شکل ۱۸.۱ شاخص «دلتا طول» (تفاوت طول استدلال در پاسخ‌های غلط نسبت به درست) را نشان می‌دهد که معیاری برای پایداری رفتاری مدل‌هاست. مدل Llama 4 Scout وقتی اشتباه می‌کند، به طور میانگین ۸ کلمه بیشتر صحبت می‌کند (میلۀ قرمز بلند)، که این یک سیگنال قوی برای تشخیص خطا است. در مقابل، مدل Claude Haiku 4.5 رفتار معکوسی دارد و در پاسخ‌های غلط کوتاه‌تر صحبت می‌کند (میلۀ سبز منفی)، که نشان‌دهنده «تسلیم شدن سریع» در برابر ابهام است.



شکل ۱۸.۱: نمودار پایداری استدلال (تفاوت طول توضیحات در پاسخ‌های غلط و درست).

نهایتاً، شکل ۱۹.۱ نقشه حرارتی (Heatmap) تمامی متریک‌ها را یکجا نمایش می‌دهد و به ما اجازه می‌دهد نقاط قوت و ضعف را در یک نگاه ببینیم. مدل Gemini 2.5 Flash با رنگ‌های آبی تیره در ستون‌های Accuracy و Efficiency، به عنوان «قهرمان تعادل» شناخته می‌شود. در مقابل، مدل GPT-OSS-20 با رنگ‌های قرمز تیره در ستون‌های Latency و Verbosity، بدترین عملکرد کلی را دارد.



شکل ۱۹.۱: نقشه حرارتی عملکرد مدل‌ها در تمامی متریک‌های ارزیابی CoT.

تحلیل‌های عمیق این بخش نشان داد که صرفاً «فعال کردن CoT» کافی نیست. مدل‌های برتر (مثل Gemini) یاد گرفته‌اند که «کوتاه و گزیده» استدلال کنند، در حالی که مدل‌های ضعیف‌تر در دام «نشخوار فکری» (Rumination) و تولید متن‌های طولانی اما بی‌په‌وده می‌افتند. برای بهبود سیستم‌های حقوقی، باید مدل‌هایی را انتخاب کرد که تراکم اطلاعاتی (Information Density) بالایی در استدلال‌های خود دارند و ستون‌های متوازی در نمودار توکن دارند.